UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL RAFAELA

- Tecnicatura Universitaria en Programación -

Introducción al Análisis de Datos



Unidad II: Naturaleza y Organización de los Datos

Docente: Ing. Darío Haspert

Curso: 2º año - 2º cuatr.

< julio de 2026 >

Índice

UNIDAD 2: Naturaleza y Organización de los Datos 3
1. Tipos de Datos: Estructurados, Semiestructurados y No Estructurados 3
1.1. Datos estructurados 3
1.2. Datos semiestructurados 3
1.3. Datos no estructurados 4
2. Escalas de medición: Nominal, Ordinal, de Intervalo y de Razón 4
2.1. Escala Nominal 4
2.2. Escala Ordinal 5
2.3. Escala de Intervalo 6
2.4. Escala de Razón 6
3. Organización de datos 7
3.1. Organización de Datos Cualitativos 7
3.2. Organización de Datos Cuantitativos 9
4. Problemáticas comunes en los datos 12
4.1. Datos faltantes/Incompletos (Missing Values) 12
4.2. Datos Incorrectos/Inexactos 13
4.3. Datos Redundantes (duplicados) 13
4.4. Datos Inconsistentes 14
4.5. Datos Desactualizados 14
4.6. Valores Atípicos (Outliers) 14
5. Fuentes de datos en el análisis de datos 16
5.1. Según su origen 17
5.2. Según su estructura 18
5.3. Según su modalidad de acceso 18
6. Importancia del análisis de datos en diferentes dominios 19
7. Ética en el análisis de datos: privacidad, sesgos, transparencia 22
Referencias Bibliográficas 25

UNIDAD 2: Naturaleza y Organización de los Datos

1. Tipos de Datos: Estructurados, Semiestructurados y No Estructurados

En el análisis de datos es fundamental identificar **cómo están organizados los datos**, ya que esto condiciona las técnicas de almacenamiento, procesamiento y análisis posibles. En función de su nivel de organización interna, los datos se clasifican en **tres grandes categorías**:

1.1. Datos estructurados

Los datos estructurados son aquellos que se organizan conforme a un modelo tabular con filas y columnas. Su estructura fija permite un acceso eficiente mediante consultas estructuradas (como SQL) y su integración con herramientas tradicionales de análisis es directa [1].

Ejemplos:

- Planillas de Excel con ventas mensuales por región.
- Base de datos de pacientes: Nombre, Edad, Diagnóstico.
- Sensores que generan datos numéricos periódicos (ej. temperatura, presión).
- Tabla relacional de inventario: ID Producto, Categoría, Precio, Stock.

Ventajas:

- Fáciles de consultar, analizar y reportar.
- Altamente compatibles con sistemas BI (Power BI, Tableau).
- Permiten validaciones automáticas por tipo de dato (número, texto, fecha).

1.2. Datos semiestructurados

Son datos que no siguen un esquema tabular rígido, pero que presentan cierta organización interna a través de etiquetas, claves o delimitadores (como XML, JSON o YAML). Son útiles cuando se necesita flexibilidad sin perder la capacidad de interpretación [2].

Ejemplos:

- Archivos JSON con información de productos en un e-commerce.
- XML de un CV digital exportado desde un portal laboral.
- Emails: contienen campos como asunto, remitente, cuerpo y adjuntos.
- Registros de logs de sistemas.
- Formularios web donde algunos campos pueden variar.

Ventajas:

- Alta adaptabilidad a contextos variables.
- Permiten almacenar datos anidados o jerárquicos.
- Ideales para la comunicación entre servicios (APIs RESTful).

1.3. Datos no estructurados

Comprenden todos aquellos datos que no presentan una estructura predefinida o formal. Su interpretación suele requerir procesamiento adicional, como análisis de lenguaje natural (NLP) o reconocimiento de patrones visuales o auditivos [3][4].

Ejemplos:

- Comentarios de usuarios en redes sociales.
- Archivos de audio de entrevistas o llamadas.
- Fotografías médicas, escaneos de documentos.
- Videos educativos o de seguridad.

Desafíos:

- Dificultades para realizar búsquedas o análisis directos.
- Alta dependencia de herramientas avanzadas (IA, visión por computador).
- Gran consumo de recursos computacionales para su procesamiento.

Comparación

Tipo de dato	Ejemplo real	Herramientas comunes
Estructurado	Base de datos SQL	Excel, SQL, Power BI
Semiestructurado	JSON de pedidos online	Python, R, MongoDB
No estructurado	Video de YouTube, texto libre	NLP, IA, OpenCV, Whisper

2. Escalas de medición: Nominal, Ordinal, de Intervalo y de Razón

Una parte fundamental en el análisis de datos consiste en comprender la **naturaleza de las variables** con las que se trabaja. No todos los datos son iguales: algunos representan categorías, otros jerarquías, y otros aún permiten realizar operaciones matemáticas complejas. Para organizar esta diversidad, se utiliza el concepto de **escalas de medición**, una clasificación propuesta inicialmente por el psicólogo Stanley Smith Stevens en 1946 [23].

Cada escala de medición determina **qué operaciones estadísticas y matemáticas son válidas** para aplicar sobre una variable, y por lo tanto, qué tipo de análisis pueden realizarse.

2.1. Escala Nominal

Es la forma más básica de medición. Agrupa datos en **categorías sin orden implícito**. Sirve simplemente para distinguir entre distintos grupos o clases. La única operación que se puede realizar es la de **igualdad/desigualdad**.

Ejemplos:

- Género: masculino, femenino, no binario
- Nacionalidad: argentina, brasileña, chilena
- Tipos de sangre (A, B, AB, O)
- Tipo de producto: alimento, medicamento, prenda

Características:

- No hay jerarquía entre los valores, ni orden.
- Solo se puede establecer **igualdad o diferencia** (y no otras operaciones aritméticas)
- Se puede calcular la **frecuencia** o el **modo**.
- Los datos son **cualitativos**.

Visual sugerida: Gráfico de barras o gráfico circular mostrando proporciones de categorías.

2.2. Escala Ordinal

Clasifica datos en **categorías ordenadas**, pero sin asumir distancias iguales entre los niveles (no es constante ni medible). Se puede establecer un "mayor que" o "menor que".

Ejemplos:

- Nivel educativo: primario < secundario < universitario
- Satisfacción: muy baja < baja < media < alta < muy alta
- Clasificación en carreras: Primer lugar, segundo lugar, tercer lugar. La diferencia de tiempo entre el primer y el segundo lugar no es necesariamente la misma que entre el segundo y el tercero.
- Nivel socioeconómico: Bajo, medio, alto.
- Grado de dolor: Leve, moderado, severo.

Características:

- Hay orden o jerarquía, pero no se puede medir la distancia entre categorías.
- Se pueden realizar comparaciones del tipo “mayor que” o “menor que”.
- Estadísticos válidos: **mediana**, **percentiles**, **rangos**.
- Los datos son **cualitativos**.

Visual sugerida: Diagrama de cajas (boxplot), gráfico de barras ordenado.

2.3. Escala de Intervalo

Esta escala incluye todas las características de la escala ordinal, pero además, la distancia entre dos valores es constante y significativa. Esto significa que podemos sumar y restar, pero no multiplicar ni dividir. La característica clave es la ausencia de un **cero absoluto**. El cero es solo un punto en la escala, no significa la ausencia de la propiedad medida.

Ejemplos:

- Temperatura en grados Celsius o Fahrenheit. El 0 °C no significa ausencia de temperatura.
- Fechas del calendario (por ejemplo: 2000, 2010, 2020). El año 0 no significa ausencia de tiempo.
- Escala de IQ (coeficiente intelectual)

Características:

- Permite realizar operaciones de suma y resta.
- No se pueden realizar proporciones (no tiene cero absoluto; el 0 es arbitrario).
- Estadísticos válidos: media, desviación estándar.
- Tiene orden y distancias iguales.
- Los datos son **cuantitativos**.

Visual sugerida: Histograma, curva normal, gráfico de dispersión.

2.4. Escala de Razón

Es la escala más completa y la más potente. Incluye todas las propiedades de las escalas anteriores y, además, tiene un **cero absoluto**. Esto significa que el valor cero indica la ausencia total de la propiedad medida. Con esta escala, se pueden realizar todas las operaciones aritméticas: suma, resta, multiplicación y división.

Ejemplos:

- Peso, altura, distancia, edad. 0 metros o 0 kilogramos significa la ausencia de esas propiedades.
- Ingresos económicos. $0 de ingresos significa que no hay dinero.
- Tiempo. 0 segundos significa ausencia de tiempo transcurrido.

Características:

- Se pueden comparar valores como múltiplos: “una persona gana el doble que otra”.
- Se aplican todas las operaciones estadísticas.
- Tiene orden, distancias iguales y un cero absoluto.
- Los datos son **cuantitativos**.
- Es la escala más rica desde el punto de vista analítico.

Visual sugerida: Gráfico de dispersión, gráfico de líneas, boxplot, un histograma.

Cuadro resumen: Escalas de medición

Escala	Orden	Distancia igual	Cero absoluto	Operaciones válidas	Ejemplos
Nominal	✗	✗	✗	Igualdad, conteo, modo	Género, nacionalidad
Ordinal	✓	✗	✗	Orden, mediana, percentiles	Nivel educativo, ranking
Intervalo	✓	✓	✗	Suma, resta, media, desviación estándar	Temperatura (°C), fechas
Razón	✓	✓	✓	Todas las operaciones estadísticas y matemáticas	Peso, ingresos, edad

El uso correcto de las escalas de medición no es un detalle técnico menor: es **la base para seleccionar el análisis estadístico adecuado** y evitar errores de interpretación. Un mal uso de la escala puede llevar a aplicar operaciones inválidas y obtener conclusiones erróneas.

💡 *El conocimiento del tipo de variable es la brújula que guía todo análisis de datos riguroso.*

3. Organización de datos

En el análisis de datos, la organización es un paso fundamental para comprender y extraer información significativa de conjuntos de datos. Permite visualizar patrones, tendencias y características clave antes de realizar análisis más complejos. Dividiremos esta sección en la organización de datos cualitativos y datos cuantitativos.

3.1. Organización de Datos Cualitativos

Los **datos cualitativos**, también conocidos como datos categóricos, describen cualidades o características que no pueden medirse numéricamente. Se expresan en palabras o categorías. Su organización busca resumir la frecuencia con la que ocurre cada categoría [39].

1.1. Tablas de Frecuencias para Datos Cualitativos

Una **tabla de frecuencias** es una herramienta fundamental para organizar datos cualitativos. Muestra las categorías de una variable y el número de veces que cada categoría aparece en el conjunto de datos [40].

- **Componentes de una tabla de frecuencias para datos cualitativos:**
    - **Categoría:** La lista de las diferentes clases o atributos de la variable cualitativa.
    - **Frecuencia Absoluta (f):** El número de veces que se repite una categoría específica.

- **Frecuencia Relativa (fr):** La proporción de veces que una categoría aparece en relación con el total de observaciones. Se calcula como fr=Nf, donde N es el número total de observaciones. Generalmente se expresa como decimal o porcentaje.
- **Frecuencia Porcentual (f%):** La frecuencia relativa expresada como porcentaje. Se calcula como f%=fr×100.

- **Ejemplo:** Supongamos que tenemos una encuesta sobre el color favorito de un grupo de personas: Rojo, Azul, Verde, Rojo, Azul, Amarillo, Rojo, Verde, Azul, Rojo.

Color Favorito	Frecuencia Absoluta (f)	Frecuencia Relativa (fr)	Frecuencia Porcentual (f%)
Rojo	4	4/10=0.4	40%
Azul	3	3/10=0.3	30%
Verde	2	2/10=0.2	20%
Amarillo	1	1/10=0.1	10%
Total	**10**	**1.0**	**100%**

1.2. Gráficos de Barras

Los **gráficos de barras** son representaciones visuales de datos cualitativos. Utilizan barras rectangulares, cuya altura o longitud es proporcional a la frecuencia de cada categoría [41].

- **Características:**
  - Las categorías se colocan en un eje (generalmente el horizontal).
  - Las frecuencias (absolutas o relativas) se colocan en el otro eje (generalmente el vertical).
  - Las barras están separadas para indicar que las categorías son distintas y no continuas.
  - Son útiles para comparar la frecuencia de diferentes categorías.
- **Cuándo usar:** Ideal para mostrar la distribución de una variable cualitativa con pocas categorías.

1.3. Gráficos de Torta (o Gráficos Circulares)

Los **gráficos de torta** son otra forma visual de representar datos cualitativos. Dividen un círculo en sectores, donde el área de cada sector es proporcional a la frecuencia relativa (o porcentaje) de cada categoría [42].

- **Características:**
  - El círculo completo representa el 100% de los datos.
  - Cada "rebanada" o sector representa una categoría.
  - El ángulo de cada sector se calcula como (Frecuencia Relativa)×360∘.

- **Cuándo usar:** Más apropiado cuando se quiere mostrar la proporción de cada categoría respecto al total. Es menos efectivo cuando hay muchas categorías (más de 5-7), ya que los sectores pueden volverse difíciles de distinguir.

3.2. Organización de Datos Cuantitativos

Los **datos cuantitativos** son aquellos que se pueden medir numéricamente y representan cantidades. Su organización es más compleja que la de los datos cualitativos, ya que pueden tomar un amplio rango de valores [43].

Las variables cuantitativas pueden ser discretas (toman valores puntuales y contables, como la edad en años) o continuas (pueden tomar cualquier valor dentro de un rango, como la altura). Esta distinción determina si conviene usar una tabla de frecuencias simple o agrupar los datos en intervalos de clase.

2.1. Tablas de Frecuencias para Datos Cuantitativos

La forma de construir tablas de frecuencias para datos cuantitativos depende de si los datos están no agrupados o agrupados.

2.1.1. Datos Cuantitativos No Agrupados

Cuando el número de valores distintos es relativamente pequeño y no hay una gran dispersión de los datos, se pueden utilizar tablas de frecuencias de manera similar a los datos cualitativos, listando cada valor único [44].

- **Componentes:**
    - **Valor del Dato (x):** Cada valor único observado en el conjunto de datos.
    - **Frecuencia Absoluta (f):** El número de veces que se repite cada valor.
    - **Frecuencia Relativa (fr):** La proporción de veces que cada valor aparece.
    - **Frecuencia Porcentual (f%):** La frecuencia relativa expresada como porcentaje.
    - **Frecuencia Acumulada (Fa):** La suma de las frecuencias absolutas hasta ese valor. Muestra cuántas observaciones son menores o iguales a un determinado valor.
    - **Frecuencia Relativa Acumulada (Fra):** La suma de las frecuencias relativas hasta ese valor.
- **Ejemplo:** Edades de un pequeño grupo de estudiantes: 18, 19, 18, 20, 21, 19, 18, 20.

Edad (x)	f	fr	f%	Fa	Fra
18	3	3/8=0.375	37.5%	3	0.375
19	2	2/8=0.250	25.0%	5	0.625
20	2	2/8=0.250	25.0%	7	0.875
21	1	1/8=0.125	12.5%	8	1.000

Total	**8**	**1.000**	**100%**		

2.1.2. Datos Cuantitativos Agrupados

Cuando se tienen muchos valores distintos o un rango amplio de datos, es más práctico agruparlos en **intervalos de clase** [45]. Esto permite una visualización y análisis más manejable.

- **Pasos para construir una tabla de frecuencias para datos agrupados:**
    1. **Determinar el Rango (R):** R=Valor Máximo−Valor Mínimo.
    2. **Determinar el Número de Clases (k):** No hay una regla fija, pero se pueden usar:
        - Regla de Sturges: $k=1+3.322\times\log10(N)$, donde N es el número total de datos. Redondear al entero más cercano [46].
        - Una opción común es que k esté entre 5 y 20, dependiendo del tamaño del conjunto de datos.
    3. **Determinar el Ancho de Clase (w):1** w=R/k. Generalmente se redondea hacia arriba para asegurar que todos los datos quepan.
    4. **Establecer los Límites de Clase:**
        - Comenzar con el valor mínimo del conjunto de datos o un valor ligeramente inferior.
        - Sumar el ancho de clase para obtener el límite superior de la primera clase.
        - Continuar de esta manera para todas las clases. Asegurarse de que las clases sean mutuamente excluyentes (un dato solo pertenece a una clase) y exhaustivas (todos los datos están en alguna clase). Es común usar la notación [LímiteInferior,LímiteSuperior], donde el límite inferior se incluye y el superior no, excepto en la última clase donde se incluye el límite superior.
    5. **Calcular la Marca de Clase (Mi):** El punto medio de cada intervalo. Mi=(Límite Inferior+Límite Superior)/2.
    6. **Contar la Frecuencia para cada Clase:** Determinar cuántos datos caen dentro de cada intervalo.
    7. **Calcular Frecuencias Relativas, Porcentuales, Acumuladas y Relativas Acumuladas:** De la misma manera que para los datos no agrupados, pero utilizando las frecuencias de las clases.
- **Componentes de una tabla de frecuencias para datos agrupados:**
    - **Intervalo de Clase:** El rango de valores que abarca cada grupo.
    - **Marca de Clase (Mi):** El punto medio de cada intervalo.
    - **Frecuencia Absoluta (f):** El número de datos que caen en cada intervalo.

- **Frecuencia Relativa (fr):** La proporción de datos en cada intervalo.
- **Frecuencia Porcentual (f%):** La frecuencia relativa expresada como porcentaje.
- **Frecuencia Acumulada (Fa):** La suma de las frecuencias absolutas hasta ese intervalo.
- **Frecuencia Relativa Acumulada (Fra):** La suma de las frecuencias relativas hasta ese intervalo.

- **Ejemplo:** Supongamos que tenemos las alturas (en cm) de 30 estudiantes:

Rango: (Max - Min) = 185 - 150 = 35 Número de clases (k) ~ 6 (por regla de Sturges para N=30) Ancho de clase (w) = 35 / 6 ~ 5.83, redondeamos a 6.

Intervalo de Clase	Marca de Clase (Mi)	f	fr	f%	Fa	Fra
[150,156)	153	5	5/30≈0.167	16.7%	5	0.167
[156,162)	159	8	8/30≈0.267	26.7%	13	0.434
[162,168)	165	7	7/30≈0.233	23.3%	20	0.667
[168,174)	171	6	6/30=0.200	20.0%	26	0.867
[174,180)	177	3	3/30=0.100	10.0%	29	0.967
[180,186]	183	1	1/30≈0.033	3.3%	30	1.000
Total		**30**	**1.000**	**100%**		

2.2. Histogramas

Un **histograma** es la representación gráfica más común para datos cuantitativos agrupados [47]. Es similar a un gráfico de barras, pero las barras están unidas para indicar la continuidad de los datos.

- **Características:**
  - En el eje horizontal se representan los límites de los intervalos de clase.
  - En el eje vertical se representan las frecuencias (absolutas o relativas).
  - Las barras son adyacentes, sin espacios entre ellas, ya que los datos son continuos.
  - El área de cada barra es proporcional a la frecuencia de la clase.
- **Cuándo usar:** Esencial para visualizar la forma de la distribución de datos cuantitativos: si es simétrica, sesgada (a la izquierda o derecha), unimodal, bimodal, etc.

2.3. Polígonos de Frecuencia

Un **polígono de frecuencia** es una gráfica de línea que conecta los puntos medios superiores de las barras de un histograma [24]. Proporciona una visión alternativa de la forma de la distribución.

- **Características:**

- Se construye uniendo los puntos medios (marcas de clase) de la parte superior de cada barra de un histograma.
- Se añaden puntos en el eje horizontal en las marcas de clase de las clases adyacentes (con frecuencia cero) para "cerrar" el polígono al eje.
- En el eje horizontal se representan las marcas de clase.
- En el eje vertical se representan las frecuencias.

- **Cuándo usar:** Útil para comparar la forma de dos o más distribuciones en el mismo gráfico. También puede ser más suave para visualizar tendencias en la distribución.

2.4. Ojivas (o Polígonos de Frecuencia Acumulada)

Una **ojiva** es una gráfica de línea que representa las frecuencias acumuladas (absolutas o relativas acumuladas) [25]. Muestra cuántas observaciones son menores o iguales a un determinado valor.

- **Características:**
  - En el eje horizontal se representan los límites superiores de los intervalos de clase.
  - En el eje vertical se representan las frecuencias acumuladas (absolutas o relativas).
  - Los puntos se grafican en el límite superior de cada clase, y se conectan con líneas.
  - La ojiva siempre es una curva no decreciente (siempre sube o se mantiene plana).
- **Cuándo usar:** Es particularmente útil para:
  - Estimación de percentiles, cuartiles y la mediana.
  - Determinar el número o la proporción de datos por debajo de un cierto valor.
  - Comparar dos o más distribuciones acumuladas.

4. Problemáticas comunes en los datos

En el mundo del **análisis de datos**, las **problemáticas fundamentales de datos** giran en torno a la calidad, disponibilidad y usabilidad de la información. Si los datos son la materia prima, estas son las deficiencias que pueden arruinar el producto final, que es el *insight* (conocimiento o revelación).

Trabajar con datos reales implica casi siempre enfrentarse a desafíos relacionados con su calidad, integridad y coherencia. A continuación, se presentan las problemáticas más comunes y sus estrategias de abordaje.

A nivel **calidad de los datos**, podemos tener:

4.1. Datos faltantes/Incompletos (Missing Values)

Causas:

- Sensores o sistemas que fallan al registrar datos.
- Usuarios que omiten responder ciertos campos.

- Restricciones de privacidad que impiden completar información.

Ejemplo:

- Encuesta sobre hábitos alimentarios donde muchos no completan el campo “consumo de verduras”.
- Registros de clientes sin número de teléfono.

Soluciones:

- Eliminación de registros con valores nulos (cuando son pocos).
- Imputación estadística: usar la media, mediana o moda del campo.
- Métodos avanzados: regresión, k-nearest neighbors, interpolación temporal [5].

4.2. Datos Incorrectos/Inexactos

Causas:

- Carga manual incorrecta o inconsistente.
- Falta de validaciones de entrada.
- Problemas de codificación o migración entre sistemas.

Ejemplo:

- Un registro de edad con el valor “mil doscientos”.
- Fechas escritas como “31/11/2025”.

Soluciones:

- Validaciones automáticas por formato y tipo de dato.
- Reglas de transformación con herramientas como Pandas o OpenRefine.
- Uso de expresiones regulares para detectar patrones anómalos [6].

4.3. Datos Redundantes (duplicados)

Causas:

- Duplicación de registros por múltiples entradas.
- Errores de escritura en nombres o identificadores.

Ejemplo:

- El mismo cliente aparece como “Ana M.” y “Ana María”.

Soluciones:

- Identificación de duplicados por claves únicas (DNI, email).
- Algoritmos de record linkage y fuzzy matching para resolver similitudes [7].

4.4. Datos Inconsistentes

Causas:

- Ingresos en distintos formatos, idiomas o unidades.
- Falta de estandarización de nomenclaturas.

Ejemplo:

- Fechas como “05/07/25”, “2025-07-05” y “07-05-25” referidas a un mismo día.
- "Buenos Aires", "Bs. As.", "CABA" para una misma ciudad.

Soluciones:

- Normalización y conversión de formatos.
- Uso de catálogos o taxonomías predefinidas.
- Validaciones cruzadas entre variables relacionadas [8].

4.5. Datos Desactualizados

Causas:

- Información que ya no es relevante
- Información que no es precisa debido al paso del tiempo

Ejemplos:

- Direcciones de clientes antiguas
- Estados de productos que cambiaron.

Soluciones:

- Implementar políticas de actualización: Establecer rutinas para revisar y actualizar los datos periódicamente.
- Utilizar sellos de tiempo: Almacenar la fecha de la última actualización para identificar datos obsoletos.
- Integrar fuentes en tiempo real: Conectar a sistemas que proveen datos dinámicos al momento.

4.6. Valores Atípicos (Outliers)

Puntos de datos que se desvían significativamente de la mayoría. Pueden ser errores genuinos o eventos raros pero reales. Deben ser manejados con cuidado, ya que pueden sesgar modelos estadísticos.

Causas:

- Errores en la Recopilación de Datos: por fallos humanos o técnicos (Errores de entrada de datos, Errores de medición)
- Variación Natural (Eventos raros pero reales, Características únicas de la población
- Problemas de Muestreo o Procesamiento (Muestreo sesgado, Errores de procesamiento).

Ejemplos:

- Lectura errónea del sensor: Un sensor registra una temperatura de 100°C. Esto es físicamente imposible para el ambiente de la sala y probablemente indica un fallo del sensor, un error de calibración o una interferencia electromagnética.
- Peso extremo: En una población general, una persona que pesa 500 kg sería un outlier significativo y podría indicar una condición médica extrema o un error de medición.
- Movimiento extremo en el precio de una acción: Si una acción de bolsa que normalmente fluctúa un 1-2% en un día, de repente cae o sube un 50% en un solo día. Esto podría deberse a noticias importantes (adquisición, escándalo), o a un error en el mercado.

Soluciones:

- **Identificación y validación:** Utilizar gráficos de caja para detectar y luego validar el origen del outlier.
- **Corregir o imputar:** Si es un error, corregirlo o reemplazarlo por un valor estimado.
- **Transformación de datos:** Aplicar transformaciones como logaritmos para reducir el impacto.
- **Métodos estadísticos robustos:** Usar la mediana en lugar de la media, ya que es menos sensible a valores extremos.

A nivel **Disponibilidad y Accesibilidad de los Datos**, las dificultades podrían ser:

- **Silos de Datos:** La información está dispersa en diferentes sistemas o departamentos dentro de una organización, sin una forma fácil de consolidarla. Cada silo tiene su propia estructura, formato y controles de acceso, lo que dificulta una vista unificada [29].
- **Falta de Acceso/Permisos:** Barreras técnicas o de seguridad que impiden a los analistas acceder a los datos que necesitan. Esto puede deberse a políticas de privacidad, regulaciones o simplemente una mala gestión de permisos.
- **Formatos Incompatibles:** Datos almacenados en diferentes formatos (CSV, JSON, XML, bases de datos SQL, NoSQL) que no se comunican fácilmente entre sí, requiriendo complejos procesos de transformación.
- **Volumen y Velocidad (Big Data Challenges):** La enorme cantidad de datos (volumen) y la velocidad a la que se generan (velocidad) pueden abrumar los sistemas tradicionales y dificultar su procesamiento y análisis en tiempo real [30].

Desde el punto de vista de la **Gobernanza y Gestión de Datos (Data Governance & Management)**, podríamos enfrentarnos a:

- **Falta de Estándares:** Ausencia de reglas claras sobre cómo se deben recolectar, almacenar y usar los datos en toda la organización. Esto lleva a inconsistencias y mala calidad [31].
- **Poca Comprensión del Origen (Data Lineage):** No saber de dónde provienen los datos, cómo se transformaron o quién los modificó, lo que dificulta la verificación de su fiabilidad.

- **Falta de Documentación (Metadatos):** No hay información sobre el significado de las columnas, las relaciones entre tablas o las reglas de negocio aplicadas. Sin metadatos, los datos son difíciles de interpretar y usar correctamente [32].
- **Cumplimiento Normativo y Privacidad:** La necesidad de cumplir con leyes de privacidad (como GDPR o CCPA) y proteger la información sensible. Esto implica anonimización, enmascaramiento de datos y controles de acceso estrictos, lo que a veces dificulta el análisis [33].

Desde la óptica de la **Integración y Transformación de Datos (ETL/ELT Challenges)**, las principales dificultades podrían ser:

- **Complejidad de la Integración:** Combinar datos de diversas fuentes con diferentes esquemas y estructuras es un proceso complejo y propenso a errores [34].
- **Necesidad de Limpieza (Data Cleansing):** Antes de analizar, los datos deben ser limpiados para corregir errores, inconsistencias y duplicados, lo cual es un proceso laborioso y que consume mucho tiempo [35].
- **Transformación de Datos:** Convertir los datos a un formato y estructura adecuados para el análisis o el modelado, lo que puede requerir lógica compleja y recursos computacionales [1].

¿Cuál podría ser el Impacto de estas problemáticas?

Estas problemáticas pueden llevar a:

- **Análisis sesgados o incorrectos:** Conclusiones erróneas que conducen a malas decisiones de negocio [37].
- **Pérdida de tiempo y recursos:** Los analistas dedican una gran parte de su tiempo a "limpiar" y preparar datos en lugar de analizarlos.
- **Falta de confianza en los datos:** Si los usuarios no confían en la información, no la usarán para la toma de decisiones.
- **Dificultad para escalar:** A medida que el volumen de datos crece, los problemas de calidad y gestión se magnifican [38].

Abordar estas problemáticas requiere una combinación de procesos, herramientas tecnológicas y una cultura organizacional que valore los datos como un activo estratégico.

5. Fuentes de datos en el análisis de datos

El punto de partida de cualquier proyecto analítico es la **obtención de los datos**. La calidad, variedad y accesibilidad de los datos condicionan todo el análisis posterior. Por ello, es esencial conocer las **distintas fuentes de datos disponibles**, sus características y limitaciones [12].

En términos generales, las fuentes de datos pueden clasificarse en función de su **origen**, **estructura**, y **modalidad de acceso** [13].

5.1. Según su origen

a) Fuentes internas

Provienen del interior de una organización o institución. Son generadas por los propios procesos administrativos, operativos o digitales.

Ejemplos:

- Ventas registradas en sistemas de facturación
- Datos de clientes en un CRM
- Registros de asistencia de personal
- Historial de navegación en una aplicación propia

Ventajas:

- Alta relevancia contextual
- Acceso controlado
- Estructura definida

Desventajas:

- Limitadas en variedad
- Posibles problemas de calidad si no hay mantenimiento

b) Fuentes externas

Provenientes de actores ajenos a la organización: instituciones públicas, redes sociales, portales especializados, sensores globales, etc.

Ejemplos:

- Datos del INDEC, Banco Mundial, OMS
- Bases de datos abiertas (open data)
- Comentarios en redes sociales
- APIs de servicios web (Twitter, Google Maps, etc.)

Ventajas:

- Gran diversidad y volumen
- Posibilidad de enriquecer el análisis
- Actualización frecuente en algunos casos

Desventajas:

- Requieren validación de calidad
- Pueden tener restricciones de acceso o licencias
- Necesitan transformación o limpieza [26]

5.2. Según su estructura

Los datos también pueden clasificarse según su estructura, tal como se desarrolló en el punto 1 (Estructurados, Semiestructurados, No estructurados)

Esta clasificación es clave para definir el enfoque analítico, las herramientas requeridas y el tipo de procesamiento necesario [27].

5.3. Según su modalidad de acceso

Modalidad	Descripción	Ejemplos
Datos abiertos	De acceso público y gratuito, promovidos por gobiernos o instituciones.	Datos.gob.ar, OpenDataSoft, Banco Mundial, INDEC
Datos propietarios	Generados por empresas u organismos privados, con acceso restringido.	Bases de clientes, reportes internos, registros de sensores
Datos de terceros	Proveen servicios vía API o suscripciones.	Twitter API, Google Analytics, OpenAI API
Web scraping	Extracción automatizada de datos desde sitios web.	Listas de precios, reseñas online, publicaciones en blogs
Sensores y IoT	Datos recolectados en tiempo real desde dispositivos físicos conectados.	Temperatura, ubicación GPS, movimientos en un gimnasio
Encuestas y relevamientos	Diseñados y ejecutados para recolectar información específica.	Formularios de Google, entrevistas, censos

Esta diversidad de accesos exige al analista habilidades no solo estadísticas, sino también técnicas y éticas [28].



Esta imagen representa las distintas **fuentes de datos**, agrupadas por origen, tipo y acceso, destacando su interconexión.

Comprender las fuentes de datos es clave no solo para obtener información útil, sino también para **evaluar su confiabilidad, completitud y pertinencia**. No todos los datos son adecuados para todo análisis, y muchas veces el desafío no es obtener más datos, sino elegir los más relevantes y de mejor calidad [12][27].

💡 *Un buen análisis comienza con una buena fuente.*

6. Importancia del análisis de datos en diferentes dominios

En la actualidad, el análisis de datos se ha consolidado como un elemento estratégico en casi todos los sectores del conocimiento y de la actividad económica. No se trata solamente de un conjunto de técnicas estadísticas o computacionales, sino de una competencia transversal que permite transformar datos en información relevante, y esta, a su vez, en conocimiento útil para la toma de decisiones.

El análisis de datos permite entender fenómenos complejos, prever escenarios futuros, optimizar procesos y evaluar el impacto de intervenciones. En un mundo donde los datos se generan en volúmenes masivos, con velocidades crecientes y gran variedad de formatos, quienes saben extraer valor de ellos poseen una ventaja decisiva, tanto en el ámbito empresarial como en el académico, público o social [13].

✓ **Industria y manufactura**

En el ámbito industrial, los datos provenientes de sensores, maquinaria, sistemas de producción o logística pueden ser analizados en tiempo real para detectar cuellos de botella, anticipar fallos técnicos y aumentar la eficiencia operativa. La aplicación de técnicas de analítica predictiva y minería de datos permite reducir tiempos de inactividad, mejorar la calidad del producto y optimizar el uso de recursos [14]. También se emplea el análisis de datos para la optimización de cadenas de producción, en el mantenimiento predictivo mediante sensores, en controles de calidad y automatización de procesos.

Ejemplos:

Una empresa de manufactura aplica modelos predictivos a datos de vibraciones y temperatura de motores para detectar anomalías que anticipan fallas, reduciendo el tiempo de parada un 30% y mejorando la planificación del mantenimiento preventivo.

Una planta automotriz utiliza sensores IoT para detectar fallas antes de que ocurran, reduciendo los tiempos de parada y los costos [9].

✓ **Finanzas**

El sector financiero ha sido uno de los pioneros en la aplicación de análisis de datos a gran escala. Las entidades bancarias, aseguradoras y bolsas de valores utilizan modelos estadísticos y de *machine learning* para realizar evaluaciones de riesgo crediticio (scoring), detección de fraudes, gestión de carteras, segmentación de clientes y estrategias de marketing. Estas herramientas no solo permiten proteger al sistema financiero, sino también ofrecer productos más personalizados [15].

Ejemplos:

Una fintech utiliza datos de comportamiento financiero (consumo, geolocalización, historial de pagos) para definir el riesgo de impago de sus usuarios y ajustar dinámicamente las tasas de interés ofrecidas.

Un banco usa machine learning para detectar patrones inusuales de gasto que podrían indicar fraude [10].

✓ **Salud**

En el campo de la salud, el análisis de datos ha revolucionado la forma en que se diagnostican enfermedades, se realiza seguimiento epidemiológico, se optimiza la gestión hospitalaria, se personalizan tratamientos médicos y es posible efectuar análisis epidemiológico en tiempo real. A través del análisis de historias clínicas electrónicas, imágenes médicas, secuencias genéticas y sensores portátiles, es posible generar conocimiento clínico de alta precisión [16].

Ejemplos:

Un hospital utiliza algoritmos de clasificación de imágenes para detectar signos tempranos de cáncer de mama en mamografías, asistiendo al diagnóstico clínico y reduciendo el tiempo de detección en un 40%.

Un centro de salud analiza miles de historias clínicas para detectar patrones tempranos de enfermedades como la diabetes tipo II [11].

✓ **Ciencia e investigación**

La investigación científica actual depende crecientemente de grandes volúmenes de datos provenientes de sensores, experimentos, encuestas o bibliografía académica. Es posible también realizar procesamiento y visualización de encuestas a gran escala, efectuar extracción de conocimiento desde literatura científica. El análisis de estos datos permite descubrir patrones, validar hipótesis, refinar modelos teóricos y comparar resultados entre distintas disciplinas. La ciencia de datos ha abierto nuevas posibilidades para campos como la biología computacional, la física de partículas, la sociología digital o la economía cuantitativa [17].

Ejemplos:

Un equipo de investigadores aplica minería de texto y análisis de redes para mapear la producción científica sobre cambio climático, identificando vacíos de conocimiento y áreas emergentes de investigación.

Investigadores usan NLP (Procesamiento del Lenguaje Natural) para clasificar y mapear estudios científicos sobre cambio climático [12].

- ✓ **Gobierno y políticas públicas**

Los gobiernos están comenzando a adoptar enfoques basados en datos para diseñar políticas públicas más efectivas, monitorear su implementación en tiempo real y aumentar la transparencia hacia la ciudadanía. Los datos abiertos, los sistemas de gestión urbana y las plataformas digitales de participación permiten mejorar la calidad de los servicios públicos y promover una gestión basada en evidencia [18].

Ejemplo:

Una municipalidad analiza patrones de movilidad urbana mediante datos de transporte público y GPS para rediseñar líneas de colectivo, reduciendo los tiempos de viaje y descongestionando zonas críticas.

- ✓ **Retail y comercio**

El sector retail fue uno de los primeros en adoptar el análisis de datos a gran escala, impulsado por la necesidad de entender el comportamiento de compra en un contexto de alta competencia y márgenes ajustados. El análisis de transacciones, patrones de navegación, historial de compras y datos de inventario permite optimizar el surtido de productos, personalizar ofertas, prevenir quiebres de stock y anticipar la demanda estacional. La combinación de datos internos (ventas, CRM) con fuentes externas (tendencias de búsqueda, clima, calendario de eventos) potencia la precisión de estas decisiones.

Ejemplos:

Una cadena de supermercados analiza el historial de compras de sus clientes para diseñar promociones personalizadas por perfil de consumo, aumentando la tasa de conversión de sus campañas de marketing.

Una tienda de indumentaria online utiliza modelos de series de tiempo para predecir la demanda de cada talle y color por temporada, reduciendo el capital inmovilizado en stock excedente.

- ✓ **Educación**

El análisis de datos en el ámbito educativo, conocido también como *learning analytics*, permite a instituciones y docentes comprender el desempeño y la trayectoria de los estudiantes a partir de datos académicos, de asistencia y de interacción con plataformas virtuales. Estos análisis facilitan la detección temprana de estudiantes en riesgo de abandono, la personalización de contenidos según el ritmo de aprendizaje individual, y la evaluación del impacto de distintas metodologías de enseñanza.

Ejemplos:

Una universidad analiza datos de asistencia, entregas de trabajos prácticos y uso del campus virtual para identificar tempranamente a estudiantes con riesgo de abandonar una materia, y activa tutorías focalizadas.

Una plataforma de educación a distancia utiliza datos de interacción (tiempo por video, intentos de evaluación) para ajustar automáticamente la secuencia de contenidos según el desempeño de cada usuario.

7. Ética en el análisis de datos: privacidad, sesgos, transparencia

El creciente uso del análisis de datos en decisiones que afectan la vida de las personas ha puesto en evidencia **la necesidad de reflexionar sobre su dimensión ética**. Los datos no son neutrales: implican relaciones de poder, impactos sociales y riesgos que deben ser considerados cuidadosamente.

a. Privacidad y protección de datos

Uno de los aspectos éticos más relevantes es la privacidad. A medida que más información personal se recolecta y analiza —desde hábitos de consumo hasta datos biométricos— aumentan los riesgos de filtraciones, usos indebidos o vigilancia masiva. La protección de los datos personales es un derecho fundamental, consagrado en leyes como el **Reglamento General de Protección de Datos (GDPR)** en Europa o la **Ley de Protección de Datos Personales N° 25.326** en Argentina [19].

Ejemplo:
Una aplicación de salud que recolecta información sobre enfermedades crónicas debe garantizar que los datos no sean compartidos con terceros (por ejemplo, aseguradoras) sin el consentimiento explícito y voluntario del usuario.

b. Sesgos algorítmicos

Los modelos de inteligencia artificial se entrenan con datos históricos. Si estos reflejan desigualdades o prejuicios, los algoritmos pueden replicarlos o incluso amplificarlos. Esto se conoce como **discriminación algorítmica** y puede afectar el acceso a servicios esenciales como salud, empleo, crédito o educación [20].

Ejemplo:
Un sistema de contratación automatizada entrenado con datos de empleados históricos tiende a favorecer varones para roles técnicos, perpetuando un sesgo de género preexistente.

c. Transparencia y explicabilidad

Otro desafío clave es la transparencia de los algoritmos. Muchas veces se utilizan modelos complejos (redes neuronales, sistemas de recomendación, etc.) cuya lógica interna no puede ser comprendida fácilmente. Esta **opacidad algorítmica** limita la posibilidad de auditar decisiones, reclamar errores o entender las razones detrás de una clasificación [21].

Ejemplo:
Un estudiante es rechazado en una universidad a través de un sistema automático de admisión. Sin transparencia, no puede saber si fue por su desempeño académico, por su lugar de residencia o por un error técnico.

Principios éticos fundamentales

Diversas organizaciones y grupos de expertos han elaborado marcos éticos para guiar el desarrollo y aplicación del análisis de datos e inteligencia artificial. Algunos de los principios más aceptados incluyen:

- **Justicia y equidad:** Evitar la discriminación por género, etnia, edad, etc.
- **Responsabilidad:** Asumir las consecuencias de las decisiones automatizadas.
- **Transparencia:** Explicar de forma clara cómo y por qué se toma una decisión.
- **Privacidad:** Minimizar la recolección de datos y garantizar su protección.
- **Seguridad:** Prevenir accesos no autorizados o usos maliciosos.
- **Participación:** Incluir a las personas afectadas en el diseño y revisión de sistemas automatizados.



Formación ética:

No basta con tener conocimientos técnicos. Los analistas de datos deben ser formados también en **pensamiento ético, compromiso social y comprensión crítica del impacto de sus modelos**. Solo así es posible construir una sociedad digital justa, inclusiva y democrática [22].

Tabla resumen de Principales Aspectos Éticos en el Análisis de Datos

Aspecto Ético	Descripción
Privacidad	Proteger los datos personales y evitar su uso o divulgación sin consentimiento.
Sesgos algorítmicos	Evitar que los modelos reproduzcan o amplifiquen prejuicios presentes en los datos históricos.
Transparencia	Asegurar que los sistemas sean comprensibles, auditables y explicables.
Justicia y equidad	Garantizar que las decisiones automatizadas no discriminen por género, raza, edad u otros factores.
Responsabilidad	Asumir las consecuencias y rendir cuentas por el impacto de los algoritmos.
Seguridad	Proteger los sistemas de accesos no autorizados y preservar la integridad de la información.
Participación	Involucrar a los usuarios en el diseño, revisión y validación de los sistemas automatizados.

Referencias Bibliográficas

[1] Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley.
[2] MongoDB Inc. (2023). *MongoDB Manual*. Recuperado de: https://www.mongodb.com/docs/manual/
[3] Marr, B. (2015). *Big Data: Using SMART Big Data, Analytics and Metrics to Make Better Decisions and Improve Performance*. Wiley.
[4] Jurafsky, D., & Martin, J. H. (2023). *Speech and Language Processing* (3ra edición, draft). Stanford University.
[5] Van Buuren, S. (2018). *Flexible Imputation of Missing Data*. CRC Press.
[6] Dasu, T., & Johnson, T. (2003). *Exploratory Data Mining and Data Cleaning*. Wiley.
[7] Christen, P. (2012). *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer.
[8] Batini, C., & Scannapieco, M. (2006). *Data Quality: Concepts, Methodologies and Techniques*. Springer.
[9] Kagermann, H., Wahlster, W., & Helbig, J. (2013). *Recommendations for implementing the strategic initiative INDUSTRIE 4.0*. Acatech.
[10] Tsay, R. S. (2010). *Analysis of Financial Time Series*. Wiley.
[11] Topol, E. (2019). *Deep Medicine: How Artificial Intelligence Can Make Healthcare Human Again*. Basic Books.
[12] Kitchin, R. (2014). *The Data Revolution: Big Data, Open Data, Data Infrastructures and Their Consequences*. Sage Publications.
[13] Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.
[14] Lee, J., Bagheri, B., & Kao, H.-A. (2015). A Cyber-Physical Systems architecture for Industry 4.0-based manufacturing systems. *Manufacturing Letters*, 3, 18-23.
[15] Kshetri, N. (2017). 1 The Emerging Role of Big Data in Key Development Issues: Opportunities, Challenges, and Concerns. *Big Data for Development*.
[16] Ristevski, B., & Chen, M. (2018). Big Data Analytics in Medicine and Healthcare. *Journal of Integrative Bioinformatics*, 15(3).
[17] Ioannidis, J. P. A. (2016). Why Most Published Research Findings Are False. *PLoS Medicine*, 2(8).
[18] Batty, M., Axhausen, K. W., Giannotti, F., Pozdnoukhov, A., Bazzani, A., Wachowicz, M., ... & Portugali, Y. (2012). Smart cities of the future. *European Physical Journal Special Topics*, 214(1), 481-518.
[19] Zarsky, T. Z. (2016). The trouble with algorithmic decisions: An analytic road map to examine efficiency and fairness in automated and opaque decision making. *Science, Technology, & Human Values*, 41(1), 118-132.
[20] Barocas, S., & Selbst, A. D. (2016). Big data's disparate impact. *California Law Review*, 104, 671.
[21] Doshi-Velez, F., & Kim, B. (2017). Towards a rigorous science of interpretable machine learning. *arXiv preprint arXiv:1702.08608*.
[22] Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence*, 1(9), 389-399.
[23] Stevens, S. S. (1946). On the theory of scales of measurement. *Science*, 103(2684), 677–680. https://doi.org/10.1126/science.103.2684.677
[26] Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys (CSUR)*, 41(3), 1–52.
[27] Donoho, D. L. (2017). 50 years of data science. *Journal of Computational and Graphical Statistics*, 26(4), 745–766.
[28] Open Data Charter (2015). Principles for open data. https://opendatacharter.net/principles/
[29] Ladley, J. (2012). Data Governance: How to Design, Deploy, and Sustain an Effective Data Governance Program. Elsevier. (Referencia a los silos de datos y la necesidad de gobernanza).
[30] Manyika, J., Chui, M., Brown, B., Bughin, J., Dobbs, R., Roxburgh, C., & Byers, A. H. (2011). Big data: The next frontier for innovation, competition, and productivity. McKinsey Global Institute. (Referencia a los desafíos de volumen y velocidad en Big Data).

[31] DAMA International. (2017). The DAMA Guide to the Data Management Body of Knowledge (DMBOK2). Technics Publications. (Referencia a la falta de estándares y la importancia de la gestión de datos).
[32] English, L. P. (1999). Improving Data Warehouse and Business Information Quality. John Wiley & Sons. (Referencia a la documentación y metadatos).
[33] General Data Protection Regulation (GDPR). Regulation (EU) 2016/679. (Referencia a la privacidad y el cumplimiento normativo).
[34] Inmon, W. H. (2002). Building the Data Warehouse. John Wiley & Sons. (Referencia a la complejidad de la integración de datos).
[35] Pyle, D. (1999). Data Preparation for Data Mining. Morgan Kaufmann. (Referencia a la necesidad de limpieza de datos).
[37] Eckerson, W. W. (2007). Performance Dashboards: Measuring, Monitoring, and Managing Your Business. John Wiley & Sons. (Referencia al impacto de datos de baja calidad en las decisiones de negocio).
[38] O'Neil, C., & Schutt, R. (2013). Doing Data Science: Straight Talk from the Frontline. O'Reilly Media. (Referencia a la escalabilidad de los problemas de datos).
[39] Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probabilidad y Estadística para Ingeniería y Ciencias*. Pearson Educación. (Frecuentemente utilizado para definir conceptos básicos de variables y datos cualitativos/cuantitativos).
[40] Triola, M. F. (2018). *Estadística*. Pearson Educación. (Libro de texto clásico que describe la construcción y el uso de tablas de frecuencias para diferentes tipos de datos).
[41] Siegel, A. F. (2016). *Practical Business Statistics*. Academic Press. (Describe los gráficos de barras como una herramienta fundamental para la visualización de datos categóricos).
[42] Moore, D. S., McCabe, G. P., & Craig, B. A. (2017). *Introduction to the Practice of Statistics*. W. H. Freeman and Company. (Explica los gráficos de pastel y sus aplicaciones, así como sus limitaciones).
[43] Spiegel, M. R., Schiller, J. J., & Srinivasan, R. A. (2013). *Probabilidad y Estadística (Serie Schaum)*. McGraw-Hill Education. (Proporciona una introducción clara a los datos cuantitativos y su tratamiento inicial).
[44] Lind, D. A., Marchal, W. G., & Wathen, S. A. (2019). *Estadística Aplicada a los Negocios y la Economía*. McGraw-Hill Education. (Aborda las tablas de frecuencias para datos no agrupados, incluyendo frecuencias acumuladas).
[45] Johnson, R. A., & Bhattacharyya, G. K. (2013). *Statistics: Principles and Methods*. John Wiley & Sons. (Explica la necesidad de agrupar datos cuantitativos y los pasos para construir tablas de frecuencias con intervalos).
[46] Sturges, H. A. (1926). "The choice of a class interval." *Journal of the American Statistical Association*, 21(153), 65-66. (La publicación original donde Herbert Sturges propuso su regla).
[47] Bluman, A. G. (2018). *Estadística Elemental: Un Enfoque Paso a Paso*. McGraw-Hill Education. (Detalla la construcción e interpretación de histogramas para datos cuantitativos).
[24] Wackerly, D. D., Mendenhall III, W., & Scheaffer, R. L. (2014). *Mathematical Statistics with Applications*. Brooks/Cole, Cengage Learning. (Aunque es más avanzado, los principios de construcción y uso de polígonos de frecuencia se derivan de la estadística descriptiva fundamental).
[25] Daniel, W. W., & Cross, C. L. (2018). *Bioestadística: Base para el análisis de las ciencias de la salud*. John Wiley & Sons. (Comúnmente se explican las ojivas en contextos donde la acumulación de frecuencias es relevante, como en la bioestadística).